

Neural Collaborative Filtering

Przemysław Rośleń 180150
Jakub Sachajko 179976

Plan prezentacji

1. Analizowany algorytm
2. Eksperyment 1 - Modyfikacje innych parametrów algorytmu
 - Eksperyment 1.1 - różne wartości learning rate
 - Eksperyment 1.2 - różne optymalizatory funkcji kosztu
 - Eksperyment 1.3 - różne wielkości warstw MLP
3. Porównanie wyników eksperymentu 1
4. Eksperyment 2 - Dodanie regularyzacji do warstw MLP oraz MF
 - Eksperyment 2.1 - dodanie regularyzacji o wartości 1
 - Eksperyment 2.2 - dodanie regularyzacji o wartości 0.1
 - Eksperyment 2.3 - dodanie regularyzacji o wartości 0.01
5. Porównanie wyników eksperymentu 2
6. Wnioski

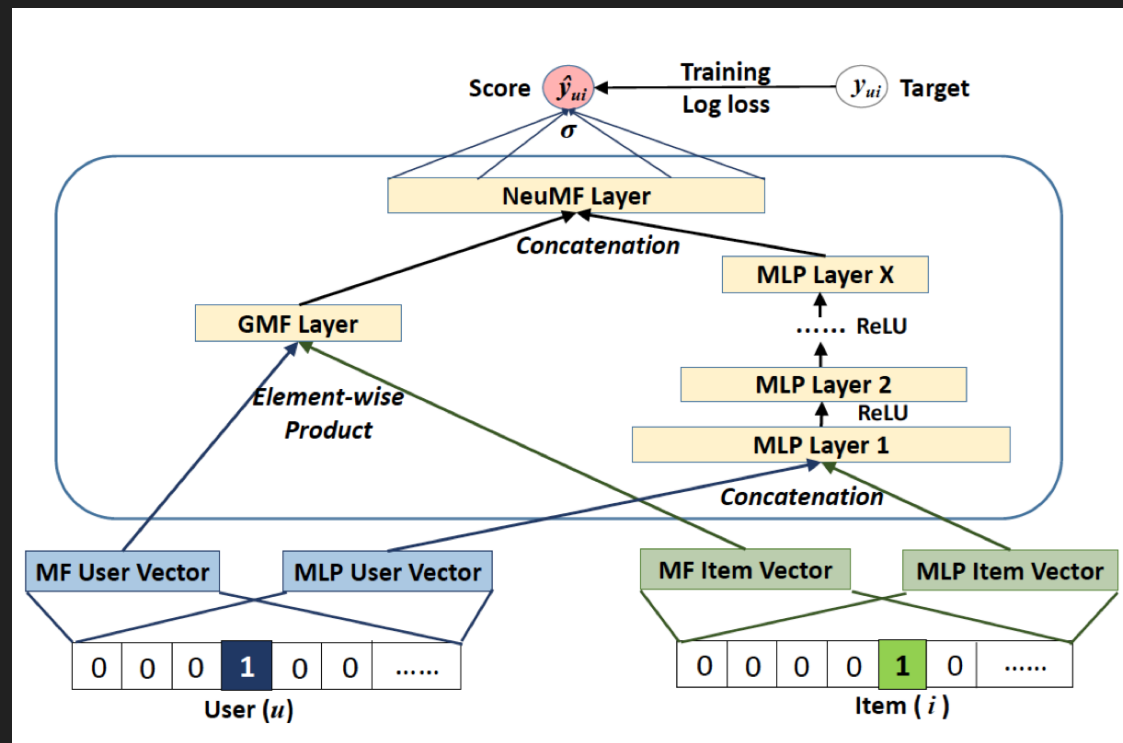

Analizowany algorytm

(a) user-item matrix

	i_1	i_2	i_3	i_4	i_5
u_1	1	1	1	0	1
u_2	0	1	1	0	0
u_3	0	1	1	1	0
u_4	1	0	1	1	1

↑ users




← items






Przebieg eksperymentu 1

- Wykorzystamy zbiór danych - MovieLens
- Kroki eksperymentu:
 - a. Wytrenowaliśmy każdy z trzech algorytmów NCF dla 3 różnych wartości parametru learning rate oraz dla 4 różnych wartości parametrów MLP layers, optimizer
 - b. Dokonaliśmy ewaluacji wyników uwzględniając metryki HR oraz NDCG
 - c. Uzyskane rezultaty porównaliśmy z tymi, uzyskanymi w poprzednich eksperymentach
- Wszystkie modyfikacje udało się przeprowadzić zgodnie z założonym planem
- Eksperyment był bardzo prosty w wykonaniu, więc nie wystąpiły żadne niespodziewane problemy




Eksperyment 1.1 - różne wartości learning rate






Eksperyment 1.2 - różne optymalizatory funkcji kosztu






Eksperyment 1.3 - różne wielkości warstw MLP



Porównanie wyników z poprzednimi eksperymentami



VS






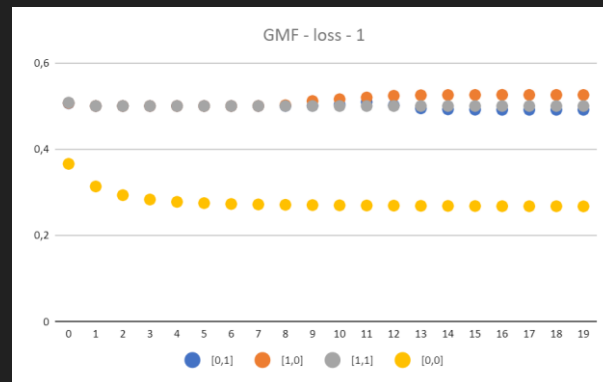


Porównanie wyników z poprzednimi eksperymentami

- Dodanie większej liczby neuronów w warstwach MLP pozwoliło na uzyskanie mniejszej wartości Loss niż w poprzednich eksperymentach (< 0.2)
- Najlepsze rezultaty metryk HR oraz NDCG w zmodyfikowanym eksperymencie niestety nie przewyższyły najwyższych wyników z poprzednich eksperymentów
- Wniosek 1: Modyfikacje parametrów learning rate oraz optimizer okazały się nie przynosić lepszych efektów (domyślne wartości są najlepsze)
- Wniosek 2: Zwiększenie liczby neuronów w warstwach MLP za pomocą parametru MLP layers pozwoliło na uzyskanie lepszych wyników

Przebieg eksperymentu 2


- Wykorzystamy zbiór danych - MovieLens
- kroki eksperymentu:
 - Zmiana parametrów `reg_layers` (default='[0,0,0,0]') oraz `reg_mf` (default=0). Opcje te zostały zmienione na liczby w postaci float z zakresu od 0 do 1 oraz w przypadku `reg_layers` można wybrać dla której warstwy zostanie przeprowadzona regularyzacja (regularyzacja L2 Lasso).
 - Testowane były warianty dla parametrów o wartościach : "1, 0.1, 0.01, 0"
 - Wyniki uzyskane dla danych eksperymentów zostały porównane i przedstawione na wykresach.
- Modyfikacje udało się zrealizować zgodnie z założonym planem.
- Wartości regularyzacji na początku były testowane dla za wysokich wartości, dlatego później z wartości w okolicy 1 wartości zostały zmniejszone na znacząco mniejsze takie jak 0.1 czy 0.01

Eksperyment 2.1 - dodanie regularyzacji o wartościach 1




Eksperyment 2.1 - NeuMF


NeuMF - HR - 1



NeuMF - NDCG - 1




NeuMF - loss - 1




Eksperyment 2.2 - dodanie regularyzacji o wartościach 0.1


GMF - HR - 0.1




GMF - NDCG - 0.1




GMF - loss - 0.1




MLP - HR - 0.1



MLP - NDCG - 0.1




MLP - loss - 0.1




Eksperyment 2.3 - dodanie regularyzacji o wartościach 0.01


GMF - HR - 0.01




GMF - NDCG - 0.01




GMF - loss - 0.01




MLP - HR - 0.01



MLP - NDCG - 0.01



MLP - loss - 0.01



Porównanie wyników z poprzednimi eksperymentami

- Wyniki są gorsze niż bez regularyzacji
- Im mniejsza wartość tym mniejsza różnica między otrzymywanymi wartościami wartości NDCG, HR i loss
- NeuMF osiąga najlepsze wyniki dla części bez regularyzacji, a część regularyzowana ma praktycznie zerowy wpływ na poprawę wartości
- Można by sprawdzić jeszcze wartości mniejsze niż 0.01 na przykład 0.0001

Wnioski końcowe

- Modyfikacje parametrów learning rate oraz optimizer nie przyniosły lepszych efektów
- Zwiększenie liczby neuronów w warstwach MLP pozwoliło na uzyskanie lepszych wyników
- Nawet bardzo mała wartość parametru regularyzacji nie dała znaczącej poprawy
- Dla dużego zbioru danych powinno używać się małych wartości parametrów regularyzacji z okolicy 0.01 oraz mniejszych wartości
- Regularyzacja nie zawsze ma pozytywny wpływ na otrzymywane wartości
- Dodanie regularyzacji nie sprawdza się w tym zastosowaniu
- Prawdopodobnie wykonanie innego rodzaju modyfikacji eksperymentów np. zwiększenie liczby epok przyniosłoby lepsze rezultaty

Źródła

1. <https://arxiv.org/pdf/1708.05031v2.pdf>
2. https://github.com/hexiangnan/neural_collaborative_filtering

Dziękujemy za uwagę